

Classification de styles artistiques par réseaux de neurones convolutifs et analyse fréquentielle

Juliette ABALAIN
Manon CHEVALIER
Albane LE VAVASSEUR

Description du sujet et objectifs

Le projet vise à concevoir un système de classification de styles artistiques capable de distinguer des mouvements (Impressionnisme, Baroque, Réalisme...) en combinant la vision par ordinateur et le Deep Learning. Dans cette optique, nous comparerons différentes architectures (ResNet, MobileNet, EfficientNet) pour identifier celle qui capture le mieux les caractéristiques visuelles des styles artistiques. L'utilisation de techniques de vision classique (analyse fréquentielle, filtres de texture) nous permettra à la fois d'établir une baseline de comparaison et d'explorer si le modèle s'appuie davantage sur la structure globale des œuvres ou sur les détails du grain pictural. Enfin, nous testerons la robustesse du système en évaluant sa capacité à généraliser à des artistes absents de la base d'entraînement, afin de vérifier qu'il apprend bien des styles génériques et non simplement les signatures individuelles de certains peintres.

Données utilisées

Nous utiliserons principalement le dataset WikiArt qui compte plus de 80 000 tableaux et 27 styles artistiques. Nous n'utiliserons qu'une partie de ce dataset pour diminuer le temps d'entraînement de nos modèles. A la fin du projet, pour tester sa robustesse, nous utiliserons notre modèle sur des photos prises par nous-mêmes dans des musées.

Plan des expériences

Etape 1 : Création des baselines

Nous allons commencer par tester des méthodes simples qui vont nous servir de points de comparaison. A l'aide de la vision classique, nous allons extraire les caractéristiques (textures, formes) des tableaux et entraîner un classifieur standard. En parallèle, nous allons mener une analyse fréquentielle pour extraire la signature spectrale des œuvres et tenter de corrélérer la densité de détails à certains styles. Enfin, nous ferons un premier test rapide avec un ResNet18 déjà entraîné sur ImageNet pour avoir un score de référence en deep learning.

Etape 2 : Optimisation architecturale

Dans cette partie, nous allons chercher à créer le meilleur modèle. Nous allons comparer 2 ou 3 réseaux différents (entre ResNet, MobileNet et EfficientNet) pour voir lequel est le plus efficace sur les œuvres d'art. Sur la meilleure architecture identifiée, nous testerons plusieurs réglages pour visualiser les influences de certains hyperparamètres (Learning rate et convergence, taux de dropout et surapprentissage par exemple). Nous testerons également plusieurs types de Data Augmentation (rotation, zoom, changement de couleurs) pour rendre notre modèle plus robuste

Etape 3 : Exploration hybride et interprétabilité

Nous allons introduire dans cette partie une dimension plus exploratoire en testant l'hypothèse de la séparation fréquentielle. L'idée est d'évaluer si un CNN entraîné sur des images filtrées passe-haut (accentuant contours et détails du trait) capture mieux certains styles qu'un CNN traitant l'image globale, ou si une architecture fusionnant plusieurs représentations fréquentielles améliore les performances. Nous utiliserons également des techniques de réduction de dimensionnalité (t-SNE ou UMAP) pour observer visuellement si les styles s'organisent selon une logique historique ou technique dans l'espace latent du modèle.

Etape 4 : Evaluation de la robustesse et analyse critique

Pour valider la capacité de généralisation réelle, nous effectuerons un split par artiste : le modèle sera testé sur des peintres dont il n'a jamais vu d'œuvres durant son entraînement. Nous pourrons ainsi vérifier que notre modèle a bien appris « le style » et pas les signatures visuelles des peintres. Enfin, nous confronterons notre modèle à des photos prises par nous-mêmes dans des musées ainsi qu'éventuellement à un autre dataset externe, afin d'identifier ses limites en conditions réelles et d'analyser les types d'erreurs commises (matrice de confusion, exemples visuels).